

「GPT-6 Astra って、結局どうなの？」

0.3% → 62.7%

わずか5か月で、「AIにはまだ無理」がかなり減った

GPT-6 Astra / OpenAI が 2026年9月に公開した最新モデル


数字は ARC-AGI-3（人間なら100%解けるよう設計された課題）での到達度 2026年3月 → 9月

何が伸びたのか

伸びたのは「知識」ではなく 「自分で作業を進める力」

評価	Sol	Astra	差
知識・推論 — ほぼ頭打ち			
GPQA Diamond	94.6%	96.0%	+1.4
自律作業 — 急伸			
AutomationBench	18.1%	41.4%	+23.3
Terminal-Bench 4.0	37.3%	57.7%	+20.4
ARC-AGI-3	7.8%	62.7%	+54.9

数問チャットで試しても差は体感できない。伸びている軸が変わった。



「Astraは99.9%」と聞いた場合 どちらも本当で、測り方が2通りあります。グラフの **62.7%** は、各社のモデルを **同じ条件に揃えて横並びで比べ** るときの数字。**99.9%** は、**途中で考えた内容を保持したまま解き進められる** 条件で、Astraの力を最大限引き出したときの数字です。他社と比較するなら前者、Astraの上限を見るなら後者。

GPT-5.6 Sol と GPT-6 Astra の比較。ARC-AGI-3 は Semi-Private。62.7%は各社共通条件、99.9%はOpenAI提供の実行環境での測定値。Source: OpenAI / ARC Prize Foundation

説明書を、渡さない試験



arcprize.org で公開されている実際のゲーム画面（Task Is20）。誰でもブラウザで遊べます。

ルール 教えない

ゴール 教えない

操作方法 教えない

探索 → 仕組みを理解
→ 目標を見つける → 計画して実行

正解を知っているかではなく、初めての環境で
「何をすべきか」を自分で組み立てられるか。

しかも「総当たり」ではない

96.0%

解けたレベルのうち、人間の中央値より
少ない操作で到達した割合

51.7%

平均で、人間よりこの割合だけ操作が少
ない

操作効率は、Astra が最高性能（99.9%）を出した条件での測定。2枚目の 62.7% とは測り方が異なる。Source: ARC Prize Foundation

実際のソフトで


同じことが、すでに起きている

画面操作（Computer Use）自体は約2年前からある機能


どちらも人間が使っているソフトそのもの

これまでは、手順を細かく指示しないと途中で失敗し、実用には遠いものでした
（当時の到達度 **22%**／同じ課題を人間がやると 約72%）。

今回上がったのは画面を操作できることではなく、その元になる「**理解して計画する**」力です。



ワープロソフトを操作し、法務文書の見出し・体裁を順に整えていく



「ゴッホ風に、金門橋も」の指示だけで Krita を操作し、白紙から描き上げる

どちらも **AI用に作り直していない**、人間が普段使っているソフトそのもの

AI化を検討できる業務の「母集団」が広がる

これまで — 絞り込まれる

すべての業務

↓ 人間が手順を分析

API を用意できる／RPA を組める
専用システムを作れる業務だけ

↓

自動化

「AIが使える形」に仕事の側を変える必要があった

これから — ほぼそのまま通る

すべての業務

↓ AI が既存ソフトを理解して使う

Excel・PowerPoint・社内Webシステム
専門端末・業務アプリ もそのまま

↓

AI化の検討対象

AIが「人間の仕事環境」に直接入る

「AIにできる業務探し」から「この仕事も渡せないか」へ

ただし

現時点の制約

コスト

約2.6万ドル

ARC-AGI-3 で 62.7% を出すのにかった費用
(1回の評価。約400万円)

※ 99.9%を出した条件では約1.9万ドル。少ない手数で解けるぶん、スコアが高い方が安いという逆転が起きている。

成果物の検証

一見、完成して
見えてしまう

Astraが設計した電子回路の基板について、専門のエンジニアからは「安全性や法規への適合は結局あらためて検証が必要」との指摘。形になることと、そのまま使えることは別。

未解決

約4割

人間なら100%解ける課題で、Astraがまだ解けていない割合（到達度は62.7%）

任せてよいかの話は別

この先に見えているもの

半導体設計

設計書を渡して

「性能・消費電力・面積を改善して」

AI研究

論文と実装を渡して

「ボトルネックを見つけて改善して」

金融工学

未整理の問題を渡して

「定式化して解法を探して」

こちらは予測ではなく事実。しかも1か月で段が上がっている

2026年8月 Astra の社内版が、数学・理論計算機科学の未解決問題 **10件で解決または大幅な進展**。Lean 4 で機械検証のうえ GitHub 公開、トークン費用は合計 約 2,000ドル。

2026年9月8日 Astra より高性能な未公開モデルが、ミレニアム懸賞問題（賞金100万ドル）の一つ **「ナビエ・ストークス方程式」** で、約1万エージェント・88時間かけて証明に到達。Lean で形式検証済み。

※ ナビエ・ストークスは4つの定式化のうち外力ありのC・Dのみで、問題の全面解決ではない。独立検証・査読はこれからで、先行研究者との経緯にも異論が出ている。**Astra本体ではなく、その次の世代が出した結果**である点も含め、この枠は「到達点」ではなく「進み方の速さ」として見ていただきたい。

「今はまだできない」を**固定した前提に置けない**

2026 / 3 ほぼ 0% → 2026 / 9 62.7%

同じ評価者が、目的によって評価を分けている

OpenAI 向けコメント

*“GPT-6 Astra delivers state-of-the-art performance on our internal coding benchmarks and shows a clear step forward in trading intuition evaluations **compared with GPT-5.6 Sol.**”*

John Crepezzi — AI Assistants, Jane Street

Anthropic 向けコメント

*“Claude Fable 5.1 solves more of our coding problems than Fable 5 or Opus 5, and **achieves state of the art on trading intuition.**”*

Craig Falls — Head of Quantitative Research, Jane Street

実務家は、**1社のモデルを妄信せず**目的別に使い分け始めている

それぞれ OpenAI 公式サイト・Anthropic 公式サイトに掲載の顧客コメント。左は Astra 社内の前モデル（GPT-5.6 Sol）比較であり、Claude との直接比較ではない。Source: openai.com, anthropic.com