

「GPT-6 Astra って、結局どうなの？」

0.3% → 62.7%

わずか5か月で、「AIにはまだ無理」がかなり減った

GPT-6 Astra / OpenAI が 2026年9月に公開した最新モデル


数字は ARC-AGI-3（人間なら100%解けるよう設計された課題）での到達度 2026年3月 → 9月

何が伸びたのか

伸びたのは「知識」ではなく 「自分で作業を進める力」

評価	Sol	Astra	差
知識・推論 — ほぼ頭打ち			
GPQA Diamond	94.6%	96.0%	+1.4
自律作業 — 急伸			
AutomationBench	18.1%	41.4%	+23.3
Terminal-Bench 4.0	37.3%	57.7%	+20.4
ARC-AGI-3	7.8%	62.7%	+54.9

数問チャットで試しても差は体感できない。伸びている軸が変わった。



GPT-5.6 Sol と GPT-6 Astra の比較。ARC-AGI-3 は Semi-Private ・ 標準ハーネス（公開前のプレビュー大会では専用エージェントが12.58%）。Source: OpenAI / ARC Prize Foundation

説明書を、渡さない試験



arcprize.org で公開されている実際のゲーム画面（Task Is20）。誰でもブラウザで遊べます。

ルール 教えない

ゴール 教えない

操作方法 教えない

探索 → 仕組みを理解
→ 目標を見つける → 計画して実行

正解を知っているかではなく、初めての環境で
「何をすべきか」を自分で組み立てられるか。

しかも「総当たり」ではない

96.0%

解けたレベルのうち、人間の中央値より
少ない操作で到達した割合

51.7%

平均で、人間よりこの割合だけ操作が少
ない

操作効率は Astra が最高性能（99.9%）を出した Provider Adapter 条件での測定。Source: ARC Prize Foundation

同じことが、すでに起きている


画面操作（Computer Use）自体は以前からある機能

Blender・Krita は人間のプロが使う市販・無料ソフト

今回上がったのは操作の元になる「理解して計画する」力。
AI向けに手を加えた特別版ではなく、人間と同じ画面をそのまま操作しています。



住宅を **Blender** で3Dモデル化
→ Unreal Engine 5 で歩ける空間へ



「ゴッホ風に、金門橋も」の指示だけで
Krita を操作し、白紙から描き上げる

どちらも **AI用に作り直していない**、人間の専門家が使ってきた道具

AI化を検討できる業務の「母集団」が広がる

これまで — 絞り込まれる

すべての業務

↓ 人間が手順を分析

API を用意できる／RPA を組める
専用システムを作れる業務だけ

↓

自動化

「AIが使える形」に仕事の側を変える必要があった

これから — ほぼそのまま通る

すべての業務

↓ AI が既存ソフトを理解して使う

Excel・PowerPoint・社内Webシステム
専門端末・業務アプリ もそのまま

↓

AI化の検討対象

AIが「人間の仕事環境」に直接入る

「AIにできる業務探し」から「この仕事も渡せないか」へ

ただし

現時点の制約

コスト

約2.6万ドル

ARC-AGI-3 で 62.7% を出すのにかった費用
(1回の評価。約400万円)

成果物の検証

「そのまま製造して
安全に使えるものではない」

公開されたCAD設計に対するエンジニアからの
批判。作れることと使えることは別。

未解決

約4割

人間なら100%解ける課題で、Astraがまだ解け
ていない割合（到達度は62.7%）

任せてよいかの話は別

この先に見えているもの

半導体設計

設計書を渡して

「性能・消費電力・面積を改善して」

AI研究

論文と実装を渡して

「ボトルネックを見つけて改善して」

金融工学

未整理の問題を渡して

「定式化して解法を探して」

こちらは予測ではなく事実 Astra の社内版が、数学・理論計算機科学の未解決問題 **10件で解決または大幅な進展**。証明は Lean 4 で機械検証のうえ GitHub 公開。トークン費用は合計 約2,000ドル。(OpenAI, 2026年8月)

「今はまだできない」を固定した前提に置けない

2026 / 3 ほぼ 0% → 2026 / 9 62.7%

同じ評価者が、目的によって評価を分けている

OpenAI 向けコメント

*“GPT-6 Astra delivers state-of-the-art performance on our internal coding benchmarks and shows a clear step forward in trading intuition evaluations **compared with GPT-5.6 Sol.**”*

John Crepezzi — AI Assistants, Jane Street

Anthropic 向けコメント

*“Claude Fable 5.1 solves more of our coding problems than Fable 5 or Opus 5, and **achieves state of the art on trading intuition.**”*

Craig Falls — Head of Quantitative Research, Jane Street

実務家は、**1社のモデルを妄信せず**目的別に使い分け始めている

それぞれ OpenAI 公式サイト・Anthropic 公式サイトに掲載の顧客コメント。左は Astra 社内の前モデル（GPT-5.6 Sol）比較であり、Claude との直接比較ではない。Source: openai.com, anthropic.com