

「GPT-6 Astra って、結局どうなの？」

0.3% → 62.7%

わずか5か月で、「AIにはまだ無理」がかなり減った

GPT-6 Astra / OpenAI が 2026年9月に公開した最新モデル


数字は ARC-AGI-3（人間なら100%解けるよう設計された課題）での到達度 2026年3月 → 9月

何が伸びたのか

伸びたのは「知識」ではなく 「自分で作業を進める力」

評価	Sol 前モデル	Astra 今回	差
知識・推論 — ほぼ頭打ち			
GPQA Diamond 大学院レベルの科学・推論問題	94.6%	96.0%	+1.4
自律作業 — 急伸			
AutomationBench 実務作業をどこまでやり切れるか	18.1%	41.4%	+23.3
Terminal-Bench 4.0 PC上の作業をやり切れるか	37.3%	57.7%	+20.4
ARC-AGI-3 説明書なしの初見課題（次ページ）	7.8%	62.7%	+54.9

数問チャットで試しても差は体感できない。伸びている軸が変わった。



「Astraは99.9%」と聞いた場合 どちらも本当で、測り方が2通りあります。62.7% は各社を同じ条件に揃えて比べたとき、99.9% は途中まで考えた内容を保持したまま解き進められる条件で、Astraの力を最大限引き出したときの数字です。

説明書を、渡さない試験



arcprize.org で公開されている実際のゲーム画面（Task Is20）。誰でもブラウザで遊べます。

ルール 教えない

ゴール 教えない

操作方法 教えない

探索 → 仕組みを理解
→ 目標を見つける → 計画して実行

正解を知っているかではなく、初めての環境で
「何をすべきか」を自分で組み立てられるか。

しかも「総当たり」ではない

96.0%

解けたレベルのうち、人間の中央値より**少ない操作**で到達した割合

51.7%

平均で、人間よりこの割合だけ**操作が少ない**

操作効率は、Astra が最高性能（99.9%）を出した条件での測定。2枚目の 62.7% とは測り方が異なる。Source: ARC Prize Foundation

実際のソフトで


同じことが、すでに起きている

人と同じようにマウスとキーボードで操作する機能は約2年前からある


どちらも人間が使っているソフトそのもの

これまでは、手順を細かく指示しないと途中で失敗し、実用には遠いものでした
(当時の到達度 **22%**／同じ課題を人間がやると 約72%)。

今回上がったのは、画面を見てマウスとキーボードを動かせることなく、
その元になる「何をすべきかを理解して、段取りを組む」力です。



ワープロソフトを操作し、法務文書の見出し・体裁を順に整えていく



「ゴッホ風に、金門橋も」の指示だけで
絵画ソフト **Krita** を操作し、白紙から描き上げる

どちらも **AI用に作り直していない**、人間が普段使っているソフトそのもの

AI化を検討できる業務の「母集団」が広がる

これまで — 絞り込まれる

すべての業務

↓ 人間が手順を分析

API を用意できる／RPA を組める
専用システムを作れる業務だけ

↓

自動化

「AIが使える形」に仕事の側を変える必要があった

API＝外部のシステムから呼び出すための接続口／RPA＝人の画面操作
を記録して自動再生する仕組み

これから — ほぼそのまま通る

すべての業務

↓ AI が既存ソフトを理解して使う

Excel・PowerPoint・社内Webシステム
専門端末・業務アプリ もそのまま

↓

AI化の検討対象

AIが「人間の仕事環境」に直接入る

「AIにできる業務探し」から「この仕事も渡せないか」へ

ただし

現時点の制約

コスト

約2.6万ドル

ARC-AGI-3 の評価を丸ごと1回走らせた費用（約400万円）。難しい課題を任せきりにするほど試行が増え、費用が跳ね上がる。

※ 文書作成のような日常的な利用の単価とは別の話。／99.9%を出した条件では約1.9万ドルで、スコアが高い方が安いという逆転も起きている。

成果物の検証

一見、完成して
見えてしまう

Astraが設計した電子回路の基板について、専門のエンジニアからは「安全性や法規への適合は結局あらためて検証が必要」との指摘。形になることと、そのまま使えることは別。

未解決

約4割

人間なら100%解ける課題で、Astraがまだ解けていない割合（到達度は62.7%）

任せてよいかの話は別

この先に見えているもの

半導体設計

設計書を渡して

「性能・消費電力・面積を改善して」

AI研究

論文と実装を渡して

「ボトルネックを見つけて改善して」

金融工学

未整理の問題を渡して

「定式化して解法を探して」

こちらは予測ではなく事実。しかも1か月で段が上がっている

2026年8月 公開前のAstraが、数学・理論計算機科学の未解決問題 **10件で解決または大幅な進展**。証明が正しいかを機械的に検証する仕組み（Lean 4）にかけたうえで GitHub 公開。費用は合計 約2,000ドル。

2026年9月8日 Astra の次の世代（未公開）が、ミレニアム懸賞問題（賞金100万ドル）の一つ 「ナビエ・ストークス方程式」 で、約1万体のAIを並列で動かし、88時間かけて証明に到達。同じく機械検証済み。

※ 9月8日の結果はAstra本体ではなく、その次の世代によるもの。Astraが古いという意味ではなく、世代交代がこの速さで進んでいるということ。なお、ナビエ・ストークスには4通りの問題設定があり、証明されたのは外から力を加える場合の2つだけで、全面解決ではない。独立検証・査読もこれからで、先行研究者との経緯には異論も出ている。

チャットとしての賢さ — これまで通りの伸び 94.6% → 96.0%

自分でPCを操作して仕事を進める力が**飛躍的に伸びた** 7.8% → 62.7%

だから、**任せられる仕事が急に広がった**

同じ評価者が、目的によって評価を分けている

OpenAI 向けコメント

*“GPT-6 Astra delivers state-of-the-art performance on our internal coding benchmarks and shows a clear step forward in trading intuition evaluations **compared with GPT-5.6 Sol.**”*

（要約）コーディングの社内評価で最高水準。トレーディングの判断力でも、前モデル Sol から明確に前進した。

John Crepezzi — AI Assistants, Jane Street

Anthropic 向けコメント

*“Claude Fable 5.1 solves more of our coding problems than Fable 5 or Opus 5, and **achieves state of the art on trading intuition.**”*

（要約）Claude Fable 5.1 は旧版より多くの課題を解き、トレーディングの判断力で最高水準に達した。

Craig Falls — Head of Quantitative Research, Jane Street

実務家は、1社のモデルを妄信せず目的別に使い分け始めている

それぞれ OpenAI 公式サイト・Anthropic 公式サイトに掲載の顧客コメント。左は Astra 社内の前モデル（GPT-5.6 Sol）比較であり、Claude との直接比較ではない。Source: openai.com, anthropic.com